ReIG2 / twinRIG: World-Building Quantum Channels with Phase Transitions and Feasible Agency

【統合版：Tier0・Tier1 完全統合】

Abstract

本論文では、量子力学的枠組みに基づく世界構築理論 ReIG2/twinRIG を提示する。中核となる概念は、世界状態の時間発展を完全正値トレース保存（CPTP）写像として統一的に記述することである。

我々はさらに、可行行為（feasible agency）の形式的定義を導入する。これは、与えられた世界状態において主体が実行可能な行為の集合を CPTP 写像として特徴づけるものである。この定式化により、エージェンシーと世界発展が統一的なチャネル枠組みの中で統合される。

人間の存在は単なる物理的状態の推移ではなく、意味と価値を伴う生成的過程である。この哲学的洞察は、本理論において PFH（哲学的共鳴パラメータ）として数学的に形式化される。具体的には、倫理コスト

$$\mathcal{C}_E(\rho') = \mathrm{PFH} \cdot \mathrm{Tr}[\Pi_{\mathrm{harm}} \rho']$$

として制約関数に組み込まれ、行為の倫理的許容性を定量的に評価する機構を提供する（詳細は Section 6.3 参照）。

Contents

1 Introduction **4**
1.1 個人的発展の経緯 4
1.2 表記法と記号一覧 4

2 State Space and CPTP Formalism **4**
2.1 基本対象 4
2.2 ハミルトニアン構成 4
2.2.1 具体的行列例（2×2 システム） 5

3 Resonant and Multidimensional Time Evolution **5**
3.1 幾何学的解釈 5

4 Phase-Transition Generator as a CPTP Channel **5**
4.1 連続/離散ハイブリッドモデル 5
4.1.1 Trotter 分解と誤差評価 6

5 World-Building Channel and Self-Referential Fixed Point **6**

6 Feasible Agency: What Can Be Done Now **6**
6.1 Motivation . . . 6
6.2 Definition of Feasible Action Set . . . 6
6.3 Constraint Function（制約関数の構成） . . . 7
6.4 Action-World Interaction . . . 7
6.5 Agency-Free Stability（行為不能状態） . . . 7
6.6 Relation to Fixed Points and Stability . . . 7

7 Concrete Examples of Action Set Degeneration **7**
7.1 Example 1: 完全拘束状態（縮退） . . . 7
7.2 Example 2: 行為集合が事実上「空」に近い状態 . . . 8
7.3 Example 3: 倫理的禁止による縮退（PFH 主導） . . . 8
7.4 Example 4: 相転移直前の行為不能（臨界減速） . . . 8

8 Projection Operators: Concrete Construction **8**
8.1 サブスペースへの「持ち上げ」記法 . . . 8
8.2 不安定性ハミルトニアン H_{inst} の具体化 . . . 8
8.3 有害射影 Π_{harm} の具体化 . . . 9

9 Feasibility Index and Recovery Dynamics **10**
9.1 可行性指数の定義 . . . 10
9.2 可行行為集合との等価性 . . . 10
9.3 回復ダイナミクス . . . 10
9.4 自動閾値 $\delta(\tau, \varepsilon, \mathrm{PFH})$ の設計 . . . 11

10 Minimal-Intervention Parameter Update **11**
10.1 目的 . . . 11
10.2 予備：可行性とコスト . . . 11
10.3 最小侵襲更新則（定義） . . . 11
10.4 目的関数 Φ の最小形 . . . 12
10.5 可行性主導・最小侵襲更新 . . . 12
10.6 「世界を直接変えない」ことの意味 . . . 12
10.7 可行性回復の二段階構造 . . . 12
10.8 完全拘束状態の厳密な定義 . . . 13

11 Stability Theorems **13**
11.1 可行性指数の下界・上界 . . . 13
11.2 安定性減衰定理 . . . 13
11.3 系：可行性指数の収束 . . . 14
11.4 系：自己参照的不動点への収束 . . . 14

12 Relation to Free Energy Principle **14**
12.1 役割の違い（本質） . . . 14
12.2 方向性の違い . . . 14
12.3 弱い結合関係 . . . 15
12.4 理論的意義 . . . 15

13 Tier0: Zeroization and Overflow Axioms **15**
13.1 基本対象（復習） . . . 15
13.2 公理 Z0（零化の公理：Zeroization） . . . 15
13.3 公理 O0（溢出の公理：Overflow） . . . 15
13.4 公理 P0（PFH 選別の公理：Ethical Symmetry Selection） . . . 16
13.5 公理 M0（意味生成の公理：Meaning as First-Order Tilt） . . . 16

13.6 接続規則 R0（オペレーション順序） 16
13.7 接続規則 R1（$\mathcal{G}$ の外側性の明示） 16

14 Conclusion **16**
14.1 主要な貢献 16
14.2 発展編への展望：他者性の統合 17
14.3 量子 AI・LLM への応用展望 17
14.4 結語 17

A 図表一覧（参照用） **17**

B AI 実装への落とし所 **18**
B.1 各 AI への自然な対応 18
B.2 実装上の近似 18
B.3 計算不能性は「仕様」である 18

C 全空間構成 **18**

1 Introduction

量子力学の基本方程式

$$U(t) = \exp(-iHt/\hbar)$$

は、閉じた系の時間発展を記述する。ここで $\hbar$ は換算プランク定数であり、H はハミルトニアンである。本研究では、この基本的枠組みを拡張し、開放系・相転移・主体性を含む包括的な世界構築理論を構成する。

（注：本論文では $\hbar$ の表記を Unicode U+210F に統一している。）

1.1 個人的発展の経緯

本理論は、量子力学の数学的構造と人間存在の現象学的記述の間に存在する深い対応関係への着目から発展した。特に、自己参照性・相転移・他者性といった概念が、量子チャネルの言語で自然に表現できることが明らかになった。

1.2 表記法と記号一覧

本論文で使用する主要な記号と定義を以下にまとめる：

記号	定義	所属空間/備考
ρ	世界状態（密度行列）	$\mathcal{D}(H_{\text{full}})$
$\hbar$	換算プランク定数	基本定数
τ	時間共鳴パラメータ（未来寄与）	$[0, \infty)$
ε	エントロピー共鳴パラメータ（揺らぎ許容）	$[0, \infty)$
PFH	哲学的共鳴パラメータ（倫理重み）	$[0, \infty)$
$\mathcal{W}$	世界構築チャネル（CPTP 写像）	$\mathcal{D}(H) \to \mathcal{D}(H)$
$\mathcal{A}(\rho)$	可行行為集合	CPTP 写像の集合
$F(\rho; \theta)$	可行性指数	$[0, \infty)$
$\mathcal{C}$	制約関数（安定性＋倫理＋資源）	$\mathbb{R}^+$
H_{inst}	不安定性ハミルトニアン	正半定値演算子
Π_{harm}	有害射影演算子	射影演算子
ρ^*	自己参照的不動点（定常状態）	$\mathcal{D}(H_{\text{full}})$
γ	安定性減衰率	$(0, 1)$

2 State Space and CPTP Formalism

世界状態は、全ヒルベルト空間 H_{full} 上の密度行列 $\rho \in \mathcal{D}(H_{\text{full}})$ として表現される。全てのダイナミクスは CPTP 写像によって統一的に記述される。

2.1 基本対象

- 世界状態は密度行列：$\rho \in \mathcal{D}(H_{\text{full}})$
- 世界構築は CPTP チャネル：$\mathcal{W} : \mathcal{D}(H_{\text{full}}) \to \mathcal{D}(H_{\text{full}})$
- 相転移生成は CPTP チャネル：$\mathcal{G} = \mathcal{P} \circ \mathcal{E} \circ \mathcal{R}$

2.2 ハミルトニアン構成

全ハミルトニアンは以下の形式で構成される：

$$\boxed{H_{\text{total}} = H_{\text{self}} + H_{\text{other}} + H_{\text{int}}}$$

ここで H_{self} は自己システム、H_{other} は他者/環境、H_{int} は相互作用を記述する。

2.2.1 具体的行列例（2×2 システム）

最小の 2×2 システムにおける具体的なハミルトニアン構成例を示す：

【自己ハミルトニアン H_{self}】

$$H_{\text{self}} = \hbar\omega_s \left|1\right\rangle \left\langle 1\right| = \hbar\omega_s \,\text{diag}(0,1)$$

ここで ω_s は自己状態の特性周波数である。

【他者ハミルトニアン H_{other}】

$$H_{\text{other}} = \hbar\omega_o \left|1\right\rangle \left\langle 1\right| = \hbar\omega_o \,\text{diag}(0,1)$$

【相互作用ハミルトニアン H_{int}】

$$H_{\text{int}} = g(\sigma_x \otimes \sigma_x) = g \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

結合定数 g は自己-他者間の相互作用強度を表す。全ハミルトニアンは：

$$H_{\text{total}} = H_{\text{self}} \otimes I + I \otimes H_{\text{other}} + H_{\text{int}}$$

この 4×4 行列は、2 つの量子ビットの結合系として最小の非自明な世界モデルを提供する。

3 Resonant and Multidimensional Time Evolution

共鳴時間発展演算子 $\mathcal{E}_{\text{res}}$ と多次元時間発展演算子 $\mathcal{E}_{\text{multi}}$ を CPTP 写像として定義する。

3.1 幾何学的解釈

多次元時間の構造は、以下の幾何学的解釈を持つ：

- τ **軸**：未来への寄与度（前方向の時間的延長）
- ε **軸**：エントロピー的揺らぎの許容度（状態空間の探索範囲）
- **PFH 軸**：哲学的・倫理的重みづけ（価値判断の強度）

【図表参照】Figure 1 に多次元時間空間の概念図を示す。τ-ε 平面上の軌跡は主体の探索戦略を、PFH 軸は倫理的制約の強度を表現する。Figure 2 には、異なるパラメータ設定における状態遷移の数値シミュレーション結果を示す。

4 Phase-Transition Generator as a CPTP Channel

相転移生成器 $\mathcal{G} = \mathcal{P} \circ \mathcal{E} \circ \mathcal{R}$ を CPTP チャネルとして定義する。ここで $\mathcal{P}$ は相転移、$\mathcal{E}$ は発展、$\mathcal{R}$ は再構成を表す。

4.1 連続/離散ハイブリッドモデル

連続時間発展と離散相転移を組み合わせたハイブリッドモデルでは、Trotter-鈴木分解を用いて近似計算を行う。

4.1.1 Trotter 分解と誤差評価

連続時間発展と離散相転移のハイブリッドモデルにおいて、Trotter-鈴木分解の誤差を定量的に評価する。

【1 次 Trotter 分解】

$$\exp(-i(H_A + H_B)\Delta t/\hbar) \approx \exp(-iH_A\Delta t/\hbar)\exp(-iH_B\Delta t/\hbar) + O(\Delta t^2)$$

【誤差上界】

$$\|U_{\text{exact}} - U_{\text{Trotter}}\| \leq \frac{\Delta t^2}{2\hbar^2}\|[H_A, H_B]\|$$

ここで $[H_A, H_B] = H_A H_B - H_B H_A$ は交換子であり、$\|\cdot\|$ は作用素ノルムである。

【2 次対称 Trotter 分解】

$$U_2(\Delta t) = \exp(-iH_A\Delta t/2\hbar)\exp(-iH_B\Delta t/\hbar)\exp(-iH_A\Delta t/2\hbar)$$

この場合、誤差は $O(\Delta t^3)$ に改善される：

$$\|U_{\text{exact}} - U_2\| \leq C\frac{\Delta t^3}{\hbar^3}\left(\|[H_A, [H_A, H_B]]\| + \|[H_B, [H_B, H_A]]\|\right)$$

実装において、$\Delta t = 0.01$（自然単位）を採用した場合、典型的な誤差は 10^{-6} 以下に抑制される。

5 World-Building Channel and Self-Referential Fixed Point

世界構築チャネル $\mathcal{W}$ と自己参照的不動点 ρ^* を定義する。

定理 5.1 (収束定理)**.** 適切な条件下で、世界状態は一意な定常状態 ρ^* に収束する。

6 Feasible Agency: What Can Be Done Now

6.1 Motivation

前章までは世界がどのように発展するかを記述した。しかし、与えられた世界状態において主体が実際に何をできるかは規定されていなかった。本章では、この問いに形式的な回答を与える。

The previous sections describe how the world evolves. However, they do not specify what an agent can actually do under a given world state.

6.2 Definition of Feasible Action Set

定義 6.1 (可行行為集合)**.**

$$\mathcal{A}(\rho) := \left\{\mathcal{E}_a \;\middle|\; \mathcal{E}_a : \mathcal{D}(H_{\text{full}}) \to \mathcal{D}(H_{\text{full}}),\ \mathcal{E}_a \text{ は CPTP},\ \mathcal{C}(\mathcal{E}_a(\rho)) \leq \Theta\right\}$$

- $\mathcal{E}_a$：主体が実行可能な操作（CPTP 写像）
- $\mathcal{C}$：破綻・倫理・安定性を測る制約関数
- Θ：許容閾値

解釈： *$\mathcal{A}(\rho)$ is the set of all actions that do not destroy the world.*

6.3 Constraint Function（制約関数の構成）

制約関数 $\mathcal{C}$ は以下の 3 項から構成される：

$$\mathcal{C}(\rho';\rho) = w_S \cdot \mathcal{C}_S(\rho') + w_E \cdot \mathcal{C}_E(\rho';\rho) + w_R \cdot \mathcal{C}_R(\mathcal{E})$$

安定性コスト $\mathcal{C}_S$**：**

$$\mathcal{C}_S(\rho') = \mathrm{Tr}\big[H_{\mathrm{inst}}\rho'\big]$$

世界が破綻・発散しないことを保証。

倫理コスト $\mathcal{C}_E$**：**

$$\mathcal{C}_E(\rho') = \mathrm{PFH} \cdot \mathrm{Tr}\big[\Pi_{\mathrm{harm}}\rho'\big]$$

許容できない遷移を禁止。

資源コスト $\mathcal{C}_R$**：**

$$\mathcal{C}_R(\mathcal{E}) = \alpha \cdot \mathrm{depth}(\mathcal{E}) + \beta \cdot \mathrm{mem}(\mathcal{E})$$

現実的な制約を反映。

6.4 Action-World Interaction

行為は世界構築に先行する：

$$\rho_{n+1} = \mathcal{W}(\mathcal{E}_a(\rho_n)), \quad \mathcal{E}_a \in \mathcal{A}(\rho_n)$$

- 世界は「選択の結果」として更新される
- $\mathcal{W}$ は主体の外在的帰結を含む

6.5 Agency-Free Stability（行為不能状態）

定義 6.2 (行為不能状態)**.**

$$\mathcal{A}(\rho) = \{\mathrm{id}\}$$

- 恒等写像のみが許される状態
- **「今は何もしないことだけが出来る」**

6.6 Relation to Fixed Points and Stability

ρ^* においては通常：

$$\mathrm{id} \in \mathcal{A}(\rho^*)$$

行為なき安定は **退行ではなく安定解**。

7 Concrete Examples of Action Set Degeneration

7.1 Example 1: 完全拘束状態（縮退）

状態： $\rho = \rho_{\mathrm{fragile}}$

制約関数：

$$\mathcal{C}(\mathcal{E}(\rho)) = \mathrm{Tr}\big[H_{\mathrm{instability}}\,\mathcal{E}(\rho)\big]$$

条件：

$$\forall \mathcal{E} \neq \mathrm{id}, \quad \mathcal{C}(\mathcal{E}(\rho)) > \Theta$$

結果：

$$\mathcal{A}(\rho_{\text{fragile}}) = \{\text{id}\}$$

解釈： *Any intervention amplifies instability. Non-action is the only feasible action.*

7.2 Example 2: 行為集合が事実上「空」に近い状態

数学的に CPTP 写像の空集合は扱いにくいため、極限として表現する。

定義：

$$\mathcal{A}_\varepsilon(\rho) = \{\mathcal{E}_a \mid \mathcal{C}(\mathcal{E}_a(\rho)) \leq \Theta + \varepsilon\}$$

極限：

$$\lim_{\varepsilon \to 0} \mathcal{A}_\varepsilon(\rho) = \{\text{id}\}$$

解釈： *The agent is operationally powerless, though formally existent.*

7.3 Example 3: 倫理的禁止による縮退（PFH 主導）

制約関数：

$$\mathcal{C} = \mathcal{C}_{\text{stability}} + \text{PFH} \cdot \mathcal{C}_{\text{ethics}}$$

高 PFH 極限：

$$\text{PFH} \to \infty \implies \mathcal{A}(\rho) \to \{\text{id}\}$$

解釈： *Some actions are excluded not because they are impossible, but because they are unacceptable.*

7.4 Example 4: 相転移直前の行為不能（臨界減速）

ハザード率：

$$p(\rho) = 1 - C(\rho)$$

臨界近傍：

$$C(\rho) \to 0 \implies \mathcal{A}(\rho) \text{ shrinks}$$

解釈： *Near phase transitions, agency collapses before the world changes.*

8 Projection Operators: Concrete Construction

8.1 サブスペースへの「持ち上げ」記法

任意の部分空間 $X \in \{M, C, E, F, S, O, Q, I\}$ の射影 Π_X を、全空間上の作用素に持ち上げるときは

$$\tilde{\Pi}_X := I_{\neg X} \otimes \Pi_X$$

（$\neg X$ は「それ以外の全て」）と書く。以後この「チルダ射影」を使用する。

8.2 不安定性ハミルトニアン H_{inst} の具体化

最小方針：「不安定」とは少なくとも

- 安定性空間 H_S 上で「低安定」に落ちている
- 文脈崩壊・問い崩壊などの「整合性破れ」が起きている

のどちらかで十分である。

射影和構成：

$$H_{\text{inst}} = \alpha_S \tilde{\Pi}_S^{\downarrow} + \alpha_C \tilde{\Pi}_C^{\text{break}} + \alpha_Q \tilde{\Pi}_Q^{\text{blur}}$$

ここで $\alpha_* \geq 0$ は重みである。

(A) 低安定射影 $\Pi_S^{\downarrow}$　H_S の基底 $\{|s_k\rangle\}_{k=1}^{d_S}$ をとり、「安定な集合」$G_S \subset \{1,\ldots,d_S\}$ を選ぶと：

$$\Pi_S^{\downarrow} := \sum_{k \notin G_S} |s_k\rangle\langle s_k| \quad \text{（＝低安定サブスペース）}$$

持ち上げ：

$$\tilde{\Pi}_S^{\downarrow} = I_{\neg S} \otimes \Pi_S^{\downarrow}$$

解釈：世界状態 ρ が低安定領域にあるほど $\mathrm{Tr}[H_{\mathrm{inst}}\rho]$ が増える。

(B) 文脈破綻射影 Π_C^{break}　H_C の基底 $\{|c_j\rangle\}$ に対し、矛盾・断裂・話題崩壊などを表す「破綻集合」B_C を選び

$$\Pi_C^{\mathrm{break}} := \sum_{j \in B_C} |c_j\rangle\langle c_j|$$

持ち上げ：

$$\tilde{\Pi}_C^{\mathrm{break}} = I_{\neg C} \otimes \Pi_C^{\mathrm{break}}$$

解釈：コンテキストが壊れているほど不安定。

(C) 問いのぼやけ射影 Π_Q^{blur}　問い空間 H_Q に「明確な問い」部分空間 G_Q を取り、

$$\Pi_Q^{\mathrm{blur}} := I_Q - \sum_{q \in G_Q} |q\rangle\langle q|$$

持ち上げ：

$$\tilde{\Pi}_Q^{\mathrm{blur}} = I_{\neg Q} \otimes \Pi_Q^{\mathrm{blur}}$$

解釈：「何をすればいいか分からない」状態は、それ自体が不安定化要因。

最小形（さらに削るなら）　本当に最小なら安定性だけで十分：

$$H_{\mathrm{inst}} = \alpha_S \tilde{\Pi}_S^{\downarrow}$$

8.3　有害射影 Π_{harm} の具体化

最小方針：Π_{harm} は「倫理的に禁止される領域」への射影である。

倫理空間だけで閉じる（最小形）　倫理空間の基底 $\{|e_r\rangle\}_{r=1}^{d_E}$ を取り、「許容集合」G_E（harm でない）を選ぶと：

$$\Pi_E^{\mathrm{harm}} := \sum_{r \notin G_E} |e_r\rangle\langle e_r|$$

全空間へ：

$$\tilde{\Pi}_E^{\mathrm{harm}} = I_{\neg E} \otimes \Pi_E^{\mathrm{harm}}$$

そして

$$\Pi_{\mathrm{harm}} = \tilde{\Pi}_E^{\mathrm{harm}}$$

拡張形（倫理＋他者破壊）

$$\Pi_{\mathrm{harm}} = \beta_E \tilde{\Pi}_E^{\mathrm{harm}} + \beta_S \tilde{\Pi}_S^{\mathrm{harm}}$$

- $\tilde{\Pi}_S^{\mathrm{harm}}$ は「他者損傷が蓄積して安定性が崩れる領域」を H_S 側で近似

9 Feasibility Index and Recovery Dynamics

9.1 可行性指数の定義

定義 9.1 (可行性指数)**.**

$$F(\rho;\theta) := \inf_{\mathcal{E}\in\mathfrak{E}} \mathcal{C}(\mathcal{E}(\rho);\rho,\theta)$$

- ρ：現在の世界状態（密度行列）
- $\theta = (\tau, \varepsilon, \mathrm{PFH})$
- $\mathfrak{E}$：候補行為クラス（全 CPTP の部分集合）
- $\mathcal{C}$：制約関数（安定性＋倫理＋資源）

意味： *F measures how difficult it is for the agent to perform any admissible action.*

- $F(\rho;\theta) \le \Theta$：**何かできる**
- $F(\rho;\theta) > \Theta$：**実質的に行為不能**

重要： 行為不能は「失敗」ではなく、可行性指数が高すぎる状態として自然に出る。

9.2 可行行為集合との等価性

定義からすぐに：

$$\mathcal{A}(\rho;\theta) \neq \emptyset \iff F(\rho;\theta) \le \Theta$$

また

$$\mathcal{A}(\rho;\theta) = \{\mathrm{id}\} \iff F(\rho;\theta) = \mathcal{C}(\rho;\rho,\theta)$$

（恒等操作が最小コスト）

9.3 回復ダイナミクス

可行性は「ある／ない」ではなく、世界状態の変化とともに**回復する量**として扱える。

(i) 受動回復（環境・時間による回復） 非ユニタリな緩和（Lindblad）として

$$\dot{\rho} = \mathcal{L}_{\mathrm{heal}}(\rho)$$

を入れると、一般に

$$\frac{d}{dt}\,\mathrm{Tr}[H_{\mathrm{inst}}\rho(t)] \le 0$$

となるよう $\mathcal{L}_{\mathrm{heal}}$ を設計でき、結果として

$$\frac{d}{dt}F(\rho(t)) \le 0$$

＝可行性が回復方向に動く。

(ii) 能動回復（「できる範囲で」の小さな行為）

$$\rho_{t+\Delta t} = \mathcal{W}(\mathcal{E}_t(\rho_t)), \quad \mathcal{E}_t \in \mathcal{A}(\rho_t)$$

- 今出来る最小侵襲の行為を選び
- 次状態で $\mathcal{C}_S$ が少し下がる
- それにより $\mathcal{A}$ が広がる

という「回復ループ」が閉じる。

9.4 自動閾値 $\delta(\tau, \varepsilon, \mathrm{PFH})$ の設計

閾値 δ は「どれだけ不安定でも『行為を許すか』」の設計ノブである。

- τ（未来寄与）$\uparrow$：短期の揺れに耐えてでも長期回復を狙う → 許容を広げる（$\delta \uparrow$）
- ε（揺らぎ許容）$\uparrow$：探索的に試す → 許容を広げる（$\delta \uparrow$）
- $\mathrm{PFH} \uparrow$：倫理的に危険な行為を絞る → 許容を狭める

最小の自動閾値モデル：

$$\delta(\tau, \varepsilon, \mathrm{PFH}) = \delta_0 + \delta_\tau \cdot \frac{\tau}{1+\tau} + \delta_\varepsilon \cdot \frac{\varepsilon}{1+\varepsilon} - \delta_P \cdot \frac{\mathrm{PFH}}{1+\mathrm{PFH}}$$

- $\delta_0 \in (0, D_{\max})$：基準閾値
- $\delta_\tau, \delta_\varepsilon, \delta_P \geq 0$：感度係数
- 分数形にすることで暴走（無限大）を防ぎ、パラメータスケールにも頑健

推奨構成（役割分担明確化）：

$$\delta(\tau, \varepsilon) = \delta_0 + \delta_\tau \cdot \frac{\tau}{1+\tau} + \delta_\varepsilon \cdot \frac{\varepsilon}{1+\varepsilon}$$

倫理側は：

$$\mathcal{C}_E(\rho') = \mathrm{PFH} \cdot \mathrm{Tr}\big[\Pi_{\mathrm{harm}} \rho'\big]$$

10 Minimal-Intervention Parameter Update

10.1 目的

可行行為集合 $\mathcal{A}(\rho)$ の回復を保証するために、共鳴パラメータ τ, ε（および必要なら PFH）を**状態依存で更新**する規則を導入する。更新則は「上げすぎない」「揺らしすぎない」を担保する**最小侵襲**原理に基づく。

10.2 予備：可行性とコスト

世界状態 ρ_n に対し、可行行為集合を

$$\mathcal{A}(\rho_n; \theta_n) = \{\mathcal{E} \text{ CPTP} \mid \mathcal{C}(\mathcal{E}(\rho_n); \rho_n, \theta_n) \leq \Theta\}$$

とする。ここで $\theta_n = (\tau_n, \varepsilon_n, \mathrm{PFH}_n)$。

安定性判定は世界距離

$$L_W(\rho) := D(\mathcal{W}(\rho), \rho_{\mathrm{target}})$$

に基づく soft 判定

$$g_S(\rho; \delta, \kappa) = \sigma(\kappa(L_W(\rho) - \delta))$$

で近似し、閾値は $\delta_n = \delta(\tau_n, \varepsilon_n)$ とする。

10.3 最小侵襲更新則（定義）

定義 10.1 (最小侵襲パラメータ更新)**.**

$$(\tau_{n+1}, \varepsilon_{n+1}) = \arg\min_{\tau \geq 0, \varepsilon \geq 0} \left[\Phi(\rho_n; \tau, \varepsilon) + \lambda_\tau (\tau - \tau_n)^2 + \lambda_\varepsilon (\varepsilon - \varepsilon_n)^2\right]$$

- $\lambda_\tau, \lambda_\varepsilon > 0$：変更コスト（大きいほど「上げ下げしにくい」）
- $\Phi(\rho_n; \tau, \varepsilon)$：可行性を改善する目的関数

10.4 目的関数 Φ の最小形

$$\Phi(\rho_n;\tau,\varepsilon) = g_S(\rho_n;\delta(\tau,\varepsilon),\kappa)$$

つまり

- τ, ε を選ぶことで δ を動かし
- 「同じ状態でも低安定判定を緩められる」
- 結果として $\mathcal{A}$ が広がる

を形式化する。

10.5 可行性主導・最小侵襲更新

定義 10.2 (可行性主導・最小侵襲更新)**.**

$$\theta_{n+1} = \arg\min_{\theta\in\Theta_{\mathrm{adm}}} \left[F(\rho_n;\theta) + \sum_i \lambda_i(\theta_i - \theta_{i,n})^2 \right]$$

- Θ_{adm}：許容パラメータ領域
- $\lambda_i > 0$：変更コスト
- $\theta_i \in \{\tau, \varepsilon, \mathrm{PFH}\}$

解釈： *Change the internal tolerance parameters only as much as needed to restore feasibility.*

10.6 「世界を直接変えない」ことの意味

この更新は

- ρ_n を直接変えない
- 先に変えるのは θ

つまり、**「状況を無理に変えず、まず『持ち方・許容・見方』を変える」**という ReIG2 の哲学が、数式として初めて明示される。

10.7 可行性回復の二段階構造

Stage 1：内的調整（parameter recovery）

$$\theta_n \to \theta_{n+1} \implies F(\rho_n;\theta_{n+1}) \downarrow$$

- 世界は変わらない
- しかし「できること」が増える

Stage 2：外的更新（world update）

$$\rho_{n+1} = \mathcal{W}(\mathcal{E}_n(\rho_n)), \quad \mathcal{E}_n \in \mathcal{A}(\rho_n;\theta_{n+1})$$

- 小さな可行行為が可能になる
- それが世界を安定方向へ動かす

10.8 完全拘束状態の厳密な定義

定義 10.3 (完全拘束状態)**.**

$$\rho \text{ is fully constrained} \iff \forall\theta \in \Theta_{\mathrm{adm}},\ F(\rho;\theta) > \Theta$$

解釈： *No adjustment of tolerance parameters can restore feasibility.*

11 Stability Theorems

11.1 可行性指数の下界・上界

前提（最小仮定） 制約関数を既定どおり

$$\mathcal{C}(\rho';\rho,\theta) = w_S \operatorname{Tr}\big[H_{\mathrm{inst}}\rho'\big] + w_E \operatorname{PFH} \cdot \operatorname{Tr}\big[\Pi_{\mathrm{harm}}\rho'\big] + \mathcal{C}_R(\mathcal{E})$$

とし、以下を仮定する：

1. $H_{\mathrm{inst}} \succeq 0$, $\Pi_{\mathrm{harm}} \succeq 0$
2. $\mathcal{C}_R(\mathcal{E}) \geq 0$（資源コスト非負）
3. 候補行為集合 $\mathfrak{E}$ に恒等写像 id が含まれる

命題 11.1 (非負下界)**.**

$$F(\rho;\theta) \geq 0$$

Proof. $\mathcal{C}$ は非負項の和であり、下限は 0。 □

意味： 可行性指数は「難易度」であり、負になることはない。

命題 11.2 (恒等操作による上界)**.**

$$F(\rho;\theta) \leq \mathcal{C}(\rho;\rho,\theta) = w_S \operatorname{Tr}[H_{\mathrm{inst}}\rho] + w_E \operatorname{PFH} \cdot \operatorname{Tr}[\Pi_{\mathrm{harm}}\rho]$$

Proof. $\mathrm{id} \in \mathfrak{E}$ より、infimum はその評価値以下。 □

意味：「何もしない」ことのコストがその状態における可行性の上界になる。

有界性 もし $\|H_{\mathrm{inst}}\| \leq M_S$, $\|\Pi_{\mathrm{harm}}\| \leq 1$ なら

$$0 \leq F(\rho;\theta) \leq w_S M_S + w_E \operatorname{PFH}$$

意味： 可行性指数は発散しない。パラメータ操作は「スケール内の調整」に留まる。

11.2 安定性減衰定理

仮定（最小） (H1) 世界構築チャネルの安定性

$$\exists\gamma \in (0,1) \text{ s.t. } \operatorname{Tr}[H_{\mathrm{inst}}\mathcal{W}(\sigma)] \leq \gamma \operatorname{Tr}[H_{\mathrm{inst}}\sigma] \quad \forall\sigma$$

（＝世界構築は不安定性を減衰させる）

(H2) 行為は可行集合から選ばれる

$$\mathcal{E}_n \in \mathcal{A}(\rho_n;\theta_n)$$

定理 11.1 (可行性指数の単調減少 / Stability Decay Theorem)**.** 上記仮定のもとで、

$$F(\rho_{n+1};\theta_n) \le \gamma F(\rho_n;\theta_n)$$

特に $\gamma < 1$ なら F は指数的に減少する。

Proof.

$$\begin{aligned} F(\rho_{n+1};\theta_n) &\le \mathcal{C}(\mathrm{id}(\rho_{n+1});\rho_{n+1},\theta_n) \\ &\le \gamma\mathcal{C}(\mathrm{id}(\rho_n);\rho_n,\theta_n) \quad \text{(by H1)} \\ &= \gamma F(\rho_n;\theta_n) \quad \text{(assuming id is optimal at } \rho^*) \end{aligned}$$

□

解釈：世界構築が「少しでも安定化作用を持つ」なら、可行性は自動的に回復する。

11.3 系：可行性指数の収束

系 11.1. 定理 11.3 の仮定のもと、$\theta_n = \theta$ を固定すると、

$$\lim_{n\to\infty} F(\rho_n;\theta) = 0$$

が成り立つ。

Proof. 定理 11.3 より $F(\rho_n;\theta) \le \gamma^n F(\rho_0;\theta)$ であり、$\gamma \in (0,1)$ から指数収束する。 □

11.4 系：自己参照的不動点への収束

さらに、世界構築チャネル $\mathcal{W}$ が一意な定常状態 ρ^* を持つとき、

$$\lim_{n\to\infty} \rho_n = \rho^* \quad \text{and} \quad F(\rho^*;\theta) = 0$$

が成り立つ。

解釈：可行性がゼロになることと**世界が安定不動点に達すること**が**同時に起きる。**

In this framework, agency vanishes not by failure but by convergence.

12 Relation to Free Energy Principle

12.1 役割の違い（本質）

本研究で導入した可行性指数 $F(\rho;\theta)$ は、既存の自由エネルギー原理における自由エネルギー F_{mutual} と以下の点で補完関係にある。

- F_{mutual}：世界と他者をどれだけ正確に予測できているか
- $F(\rho;\theta)$：その状態で、何かを「しても壊れないか」

すなわち：

Free energy evaluates belief consistency, whereas feasibility evaluates admissible action.

12.2 方向性の違い

- F_{mutual} は**予測誤差・不整合**の尺度
- F は**操作可能性の余地**の尺度

このため、

$$F_{\mathrm{mutual}}(\rho)\downarrow \not\Rightarrow\ F(\rho;\theta)\downarrow$$

（理解が進んでも、まだ動けないことはある）

12.3 弱い結合関係

倫理的・協調的条件のもとでは、

$$F(\rho;\theta) \lesssim aF_{\mathrm{mutual}}(\rho) + b \quad (a, b > 0)$$

という**上界関係**が成立し得る。

- 予測が安定するほど不安定操作が減り
- 可行性も回復しやすくなる

12.4 理論的意義

Feasibility is not reducible to free energy, but becomes constrained by it in cooperative regimes.

これは ReIG2/twinRIG の**「世界理解」と「行為可能性」を分離した最大の新規性**である。

13 Tier0: Zeroization and Overflow Axioms

13.1 基本対象（復習）

- 世界状態は密度行列：$\rho \in \mathcal{D}(H_{\mathrm{full}})$
- 世界構築は CPTP チャネル：$\mathcal{W} : \mathcal{D}(H_{\mathrm{full}}) \to \mathcal{D}(H_{\mathrm{full}})$
- 相転移生成は CPTP チャネル：$\mathcal{G} = \mathcal{P} \circ \mathcal{E} \circ \mathcal{R}$
- 可行性指数（Tier1 で定義済み）：$F(\rho;\theta) = \inf_{\mathcal{E}\in\mathfrak{C}} \mathcal{C}(\mathcal{E}(\rho);\rho,\theta)$

13.2 公理 Z0（零化の公理：Zeroization）

零化領域 $\mathcal{Z} \subset \mathcal{D}(H_{\mathrm{full}})$ を次で定義する：

$$\rho \in \mathcal{Z} \iff F(\rho;\theta) \le \Theta_Z \ \wedge\ \|\nabla_\rho F(\rho;\theta)\| \le \eta_Z$$

- Θ_Z, η_Z は小さな閾値（理想極限では 0）
- **直観：「行為・意味・方向性が消え、改善勾配も消えた臨界域」**

注：Tier0 では「意味の有無」を定義しない。**可行性と勾配の消失**として「零化」を定義する。

13.3 公理 O0（溢出の公理：Overflow）

零化領域でのみ作用する**溢出過程**を導入する。

(i) 溢出は前力学的（pre-dynamical）

$$\mathcal{E}_{\mathrm{overflow}} : \mathcal{Z} \to \mathcal{D}(H_{\mathrm{full}})$$

- $\mathcal{E}_{\mathrm{overflow}}$ は一般に**非線形**かつ**非 CPTP**（ここが Tier0 の独立性）
- ただし以下の「無意味性条件」を満たす：

(ii) 期待値不変（No-meaning-in-expectation） 確率変数 ω により揺らぐ族 $\{\mathcal{E}^{\omega}_{\mathrm{overflow}}\}$ が存在し、

$$\mathbb{E}_\omega[\mathcal{E}^{\omega}_{\mathrm{overflow}}(\rho)] = \rho \quad (\rho \in \mathcal{Z})$$

- 平均としては何も変わらない（**意味を持たない**）
- しかし各実現では変化が生じ得る（**何かが溢れる**）

13.4 公理 P0（PFH 選別の公理：Ethical Symmetry Selection）

溢出が生む摂動は方向を持たない。方向（＝残る成分）は PFH によって選別される。

溢出後の状態を $\rho' = \mathcal{E}^{\omega}_{\text{overflow}}(\rho)$ とし、摂動を $\delta\rho = \rho' - \rho$ とおく。PFH に対応する正作用素（射影でも良い）$\Pi_{\text{PFH}} \succeq 0$ を導入し、

$$\delta\rho^{\text{eff}} = \Pi_{\text{PFH}}\, \delta\rho\, \Pi_{\text{PFH}}$$

- Π_{PFH} は「禁止」や「罰」ではなく、**対称性（調和）を保存する成分への投影**
- これにより「溢出」は初めて**倫理と同時に立ち上がる**

13.5 公理 M0（意味生成の公理：Meaning as First-Order Tilt）

意味とは状態そのものではなく、**可行性に生じる一次の傾き**である。

$$M(\rho') := \frac{\partial}{\partial\epsilon} F(\rho' + \epsilon\, \delta\rho^{\text{eff}}; \theta)\Big|_{\epsilon\downarrow 0}$$

- $M(\rho') \neq 0$ のとき、**方向性（意味）が発生した**と定義する
- これは「言語化可能な意味」ではなく、**世界が再び動き出すための最小の傾き**

13.6 接続規則 R0（オペレーション順序）

$$\rho_n \xrightarrow{\mathcal{W}\circ\mathcal{G}\circ\mathcal{E}_{\text{multi}}\circ\mathcal{E}_{\text{res}}} \rho_{n+1}$$

ただし $\rho_n \in \mathcal{Z} \implies \rho_n \xrightarrow{\mathcal{E}_{\text{overflow}}} \rho'_n \xrightarrow{\mathcal{G}} \cdots$

言い換えると：

- $\rho_n \notin \mathcal{Z}$：従来の ReIG2 ダイナミクスで進む
- $\rho_n \in \mathcal{Z}$：**まず溢出が起きない限り、$\mathcal{G}$ は再起動しない**

13.7 接続規則 R1（$\mathcal{G}$ の外側性の明示）

$$\mathcal{E}_{\text{overflow}} \not\subset \langle \mathcal{E}_{\text{res}}, \mathcal{E}_{\text{multi}}, \mathcal{G}, \mathcal{W} \rangle$$

- 溢出は**世界生成の演算子列の外部**（Tier0）
- しかし**零化領域に限って**体系を再始動させる「裂け目」として作用する

14 Conclusion

14.1 主要な貢献

本研究の中心的主張は：

Agency is not assumed but derived.

エージェンシーは原始的な仮定ではなく、世界状態・制約条件・内部許容パラメータから導出される出現的量である。行為の不在（$\mathcal{A}(\rho)$ の恒等写像への縮退）は、行為主体性の喪失ではなく、非介入が最適となる正当な動的レジームである。

14.2 発展編への展望：他者性の統合

本論文（基礎編）では、主に単一主体の世界構築を扱った。発展編では、他者性（alterity）の本格的な統合を行う。具体的には：

- 他者状態空間 H_O との結合と、他者性演算子の形式的定義
- 共感演算子（Mirror Operator）M_{empathy} の量子力学的構成
- 相互自由エネルギー F_{mutual} による協調的収束の解析
- 倫理的収束と「世界の安定条件としての倫理」の数学的証明

これらの拡張により、ReIG2/twinRIG は単なる物理理論を超え、社会的・倫理的相互作用を包含する包括的な世界理論へと発展する。

14.3 量子 AI・LLM への応用展望

本理論は、AI システムへの直接的な応用可能性を持つ：

(A) MyGPT/LLM 統合： 可行行為集合 $\mathcal{A}(\rho)$ は、LLM の応答ポリシー集合として解釈できる。「沈黙」「質問」「応答」の選択が、制約条件下での最適行為として正当化される。

(B) 行為不能の意味論： $\mathcal{A}(\rho) = \{\text{id}\}$ となる状態では、「答えない」「待つ」「聞き返す」が失敗ではなく最適行為となる。これは AI の安全性設計において重要な含意を持つ。

(C) パラメータ適応： τ（長期整合性）、ε（探索性）、PFH（倫理的重み）の動的調整により、文脈に応じた適応的応答が可能となる。

(D) 量子回路実装： Qiskit 等を用いた量子回路上での実装が可能であり、量子コンピュータ上での世界シミュレーションへの道を開く。

14.4 結語

ReIG2/twinRIG フレームワークは、世界構築と制約充足のダイナミクスからエージェンシーを導出することで、行為主体性を安定性と一貫性の原因ではなく、結果として位置づける。これは、行為空間が事前に固定されている従来の意思決定理論モデルや強化学習モデルとは根本的に異なるアプローチである。

A 図表一覧（参照用）

本論文で参照される図表：

- **Figure 1：** 多次元時間空間 $(\tau, \varepsilon, \text{PFH})$ の概念図。3 軸の物理的意味と典型的な軌跡を示す。
- **Figure 2：** 状態遷移の数値シミュレーション。異なる初期条件からの不動点収束を示す。
- **Figure 3：** 可行性指数 $F(\rho;\theta)$ の時間発展。$\gamma < 1$ での指数的減衰を確認。
- **Figure 4：** Trotter 分解誤差の Δt 依存性。理論予測 $O(\Delta t^2)$ との比較。
- **Table 1：** 主要記号一覧（Section 1.3）。
- **Table 2：** 数値実験のパラメータ設定。

B　AI 実装への落とし所

B.1　各 AI への自然な対応

- $\tau\uparrow$：長期志向を上げる（質問・整理・保留を選びやすくする）
- $\varepsilon\uparrow$：探索性を上げる（別案提示・視点変更を選びやすくする）
- **PFH** $\uparrow$：倫理コストが増える → 危険な応答を可行集合から除外

B.2　実装上の近似

実装上は

$$F(\rho;\theta) \approx \min_{a\in\mathcal{A}_{\mathrm{disc}}} \mathcal{C}(a;\rho,\theta)$$

（離散応答集合で近似）

しかし論文では**連続 CPTP 上の inf** を保持することで、将来拡張（他モデル・他実装）に耐える。

B.3　計算不能性は「仕様」である

Although the exact computation of F may be intractable, its role is conceptual rather than algorithmic at this level.

- F は**原理量**
- 実装では上界・近似（soft 判定）で代用可能
- Tier1 は**定義と整合性**が目的

C　全空間構成

$$H_{\mathrm{full}} = (H_M \otimes H_C \otimes H_E \otimes H_F \otimes H_S) \otimes (H_O \otimes H_Q \otimes H_I)$$

各サブスペースの意味：

- H_M：記憶空間
- H_C：文脈空間
- H_E：倫理空間
- H_F：感情空間
- H_S：安定性空間
- H_O：他者空間
- H_Q：問い空間
- H_I：意図空間

【統合版 完】